Практическая работа №4.Методы кластеризации

Алгоритм K-средних

Алгоритм кластеризации K-средних является одним из известных алгоритмов кластеризации данных. Нужно предположить, что номера кластеров уже известны. Это также называется плоской кластеризацией. Это алгоритм итеративной кластеризации. Для этого алгоритма необходимо выполнить следующие шаги:

Шаг 1 — Нам нужно указать желаемое количество K подгрупп.

Шаг 2 — Зафиксируйте количество кластеров и случайным образом назначьте каждую точку данных кластеру. Или, другими словами, нам нужно классифицировать наши данные на основе количества кластеров.

На этом этапе кластерные центроиды должны быть вычислены.

Поскольку это итеративный алгоритм, нам нужно обновлять местоположения K центроидов с каждой итерацией, пока мы не найдем глобальные оптимумы или, другими словами, центроиды достигают в своих оптимальных местоположениях.

Следующий код поможет в реализации алгоритма кластеризации K-средних в Python. Мы собираемся использовать модуль Scikit-learn.

Давайте импортируем необходимые пакеты

```
importmatplotlib.pyplotasplt
import seaborn as sns; sns.set()
import numpy as np
from sklearn.cluster import KMeans
```

Следующая строка кода поможет в создании двумерного набора данных, содержащего четыре **больших объекта** , с помощью **make_blob** из пакета **sklearn.dataset** .

```
from sklearn.datasets.samples_generator import make_blobs

X, y_true = make_blobs(n_samples = 500, centers = 4,
cluster_std = 0.40, random_state = 0)
```

Мы можем визуализировать набор данных, используя следующий код

```
plt.scatter(X[:, 0], X[:, 1], s = 50)
plt.show()
```

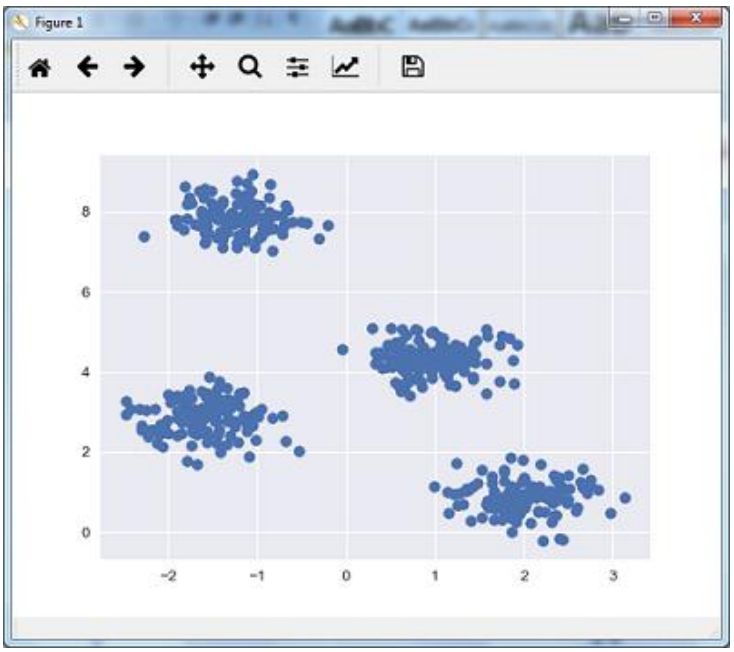

Здесь мы инициализируем kmeans в качестве алгоритма KMeans с обязательным параметром количества кластеров (n_clusters).

```
kmeans = KMeans(n_clusters = 4)
```

Нам нужно обучить модель K-средних с входными данными.

```
kmeans.fit(X)
y_kmeans = kmeans.predict(X)
plt.scatter(X[:, 0], X[:, 1], c = y_kmeans, s = 50, cmap = 'viridis')

centers = kmeans.cluster_centers_
```

Код, приведенный ниже, поможет нам построить и визуализировать результаты работы машины на основе наших данных, а также в соответствии с количеством найденных кластеров.

```
plt.scatter(centers[:, 0], centers[:, 1], c = 'black', s = 200, alpha = 0.5);
plt.show()
```

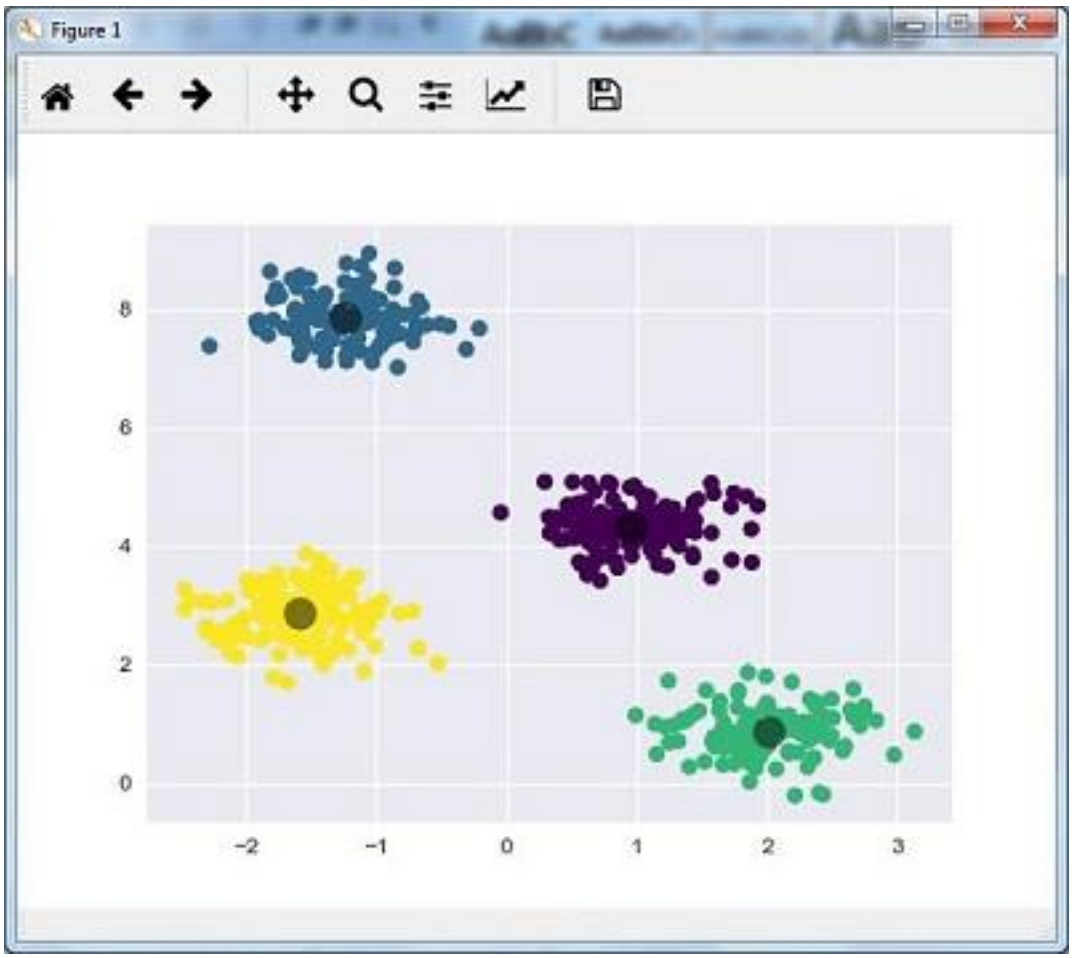

Алгоритм среднего смещения

Это еще один популярный и мощный алгоритм кластеризации, используемый в обучении без учителя. Он не делает никаких предположений, следовательно, это непараметрический алгоритм. Это также называется иерархической кластеризацией или кластерным анализом среднего сдвига. Ниже приведены основные шаги этого алгоритма —

- Прежде всего, нам нужно начать с точек данных, назначенных на собственный кластер.
- Теперь он вычисляет центроиды и обновляет местоположение новых центроидов.
- Повторяя этот процесс, мы приближаемся к вершине кластера, т.е. к области более высокой плотности.
- Этот алгоритм останавливается на стадии, когда центроиды больше не двигаются.

С помощью следующего кода мы реализуем алгоритм кластеризации Mean Shift в Python. Мы собираемся использовать модуль Scikit-learn.Давайте импортируем необходимые пакеты

```
import numpy as np
from sklearn.cluster import MeanShift
import matplotlib.pyplot as plt
from matplotlib import style
style.use("ggplot")
```

Следующий код поможет в создании двумерного набора данных, содержащего четыре **больших объекта** , с помощью **make_blob** из пакета **sklearn.dataset** .

```
from sklearn.datasets.samples_generator import make_blobs
```

Мы можем визуализировать набор данных с помощью следующего кода

```
centers = [[2,2],[4,5],[3,10]]
X, _ = make_blobs(n_samples = 500, centers = centers, cluster_std = 1)
plt.scatter(X[:,0],X[:,1])
plt.show()
```

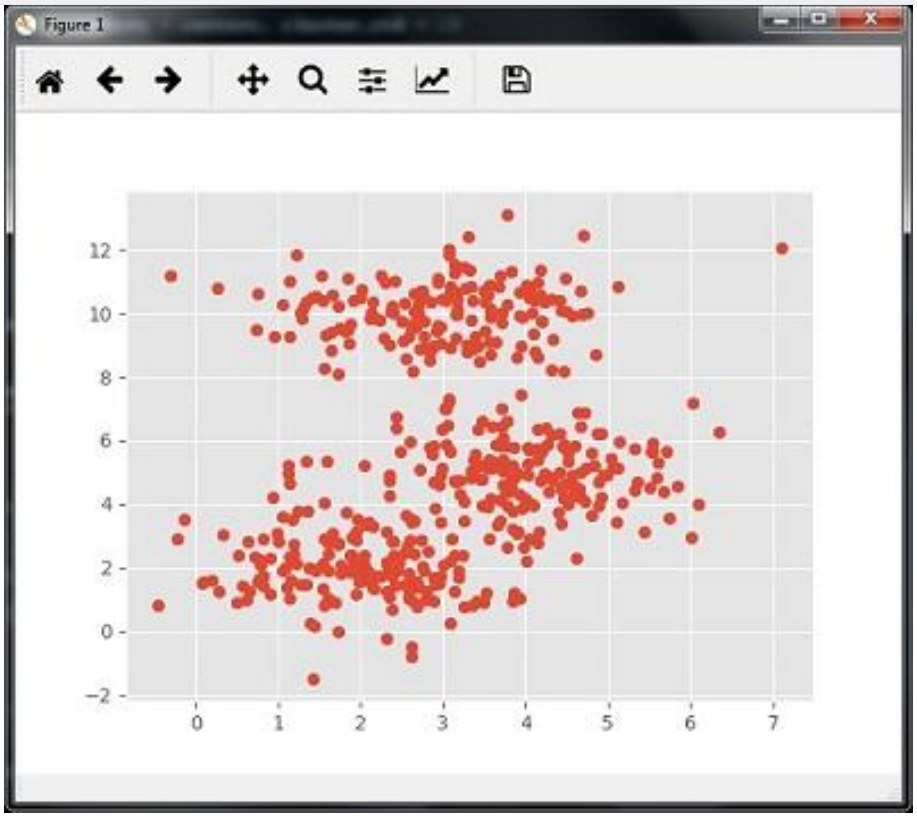

Теперь нам нужно обучить кластерную модель Mean Shift с использованием входных данных.

```
ms = MeanShift()
ms.fit(X)
labels = ms.labels_
cluster_centers = ms.cluster_centers_
```

Следующий код напечатает центры кластеров и ожидаемое количество кластеров согласно входным данным

```
print(cluster_centers)
n_clusters_ = len(np.unique(labels))
print("Estimated clusters:", n_clusters_)
[[ 3.23005036 3.84771893]
[ 3.02057451 9.88928991]]
Estimated clusters: 2
```

Код, приведенный ниже, поможет построить и визуализировать результаты работы машины на основе наших данных, а также соответствия в соответствии с количеством найденных кластеров.

```
colors = 10*['r.','g.','b.','c.','k.','y.','m.']
   for i in range(len(X)):
   plt.plot(X[i][0], X[i][1], colors[labels[i]], markersize = 10)
```

```
plt.scatter(cluster_centers[:,0],cluster_centers[:,1],
   marker = "x",color = 'k', s = 150, linewidths = 5, zorder = 10)
plt.show()
```

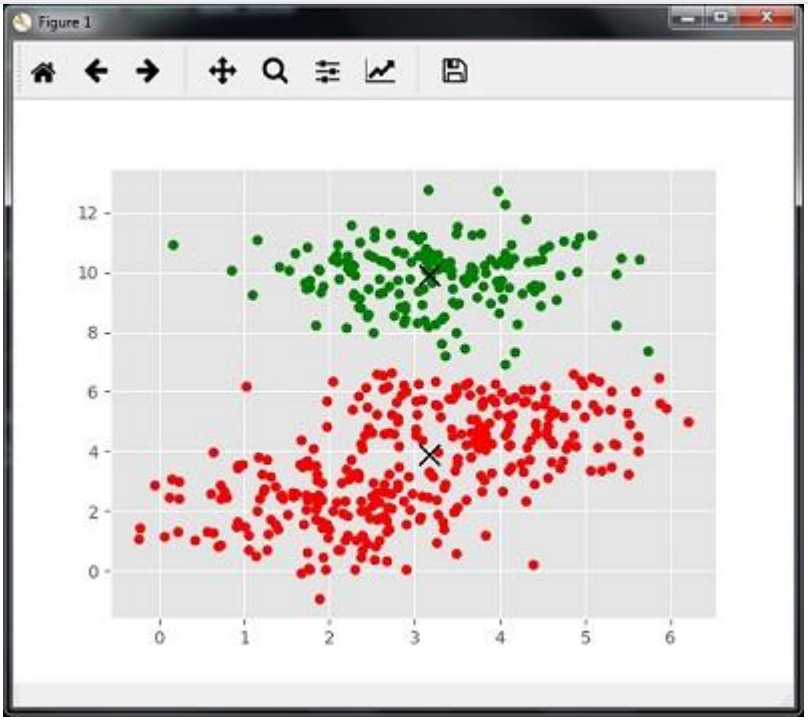

Нахождение ближайших соседей

Если мы хотим создать рекомендательные системы, такие как система рекомендования фильмов, то нам нужно понять концепцию поиска ближайших соседей. Это потому, что система рекомендации использует концепцию ближайших соседей.

Концепция нахождения ближайших соседей может быть определена как процесс нахождения ближайшей точки к точке входа из данного набора данных. Основное использование этого алгоритма KNN) K-ближайших соседей) заключается в создании систем классификации, которые классифицируют точку данных о близости точки входных данных к различным классам.

Код Python, приведенный ниже, помогает найти K-ближайших соседей заданного набора данных. Импортируйте необходимые пакеты, как показано ниже. Здесь мы используем модуль **NearestNeighbors** из пакета **sklearn**

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.neighbors import NearestNeighbors
```

Давайтетеперьопределимвходныеданные

```
A = np.array([[3.1, 2.3], [2.3, 4.2], [3.9, 3.5], [3.7, 6.4], [4.8, 1.9],
[8.3, 3.1], [5.2, 7.5], [4.8, 4.7], [3.5, 5.1], [4.4, 2.9],])
```

Теперь нам нужно определить ближайших соседей

```
k = 3
```

Нам также нужно предоставить тестовые данные, из которых можно найти ближайших соседей

```
test_data = [3.3, 2.9]
```

Следующий код может визуализировать и построить входные данные, определенные нами

```
plt.figure()
plt.title('Input data')
plt.scatter(A[:,0], A[:,1], marker = 'o', s = 100, color = 'black')
```

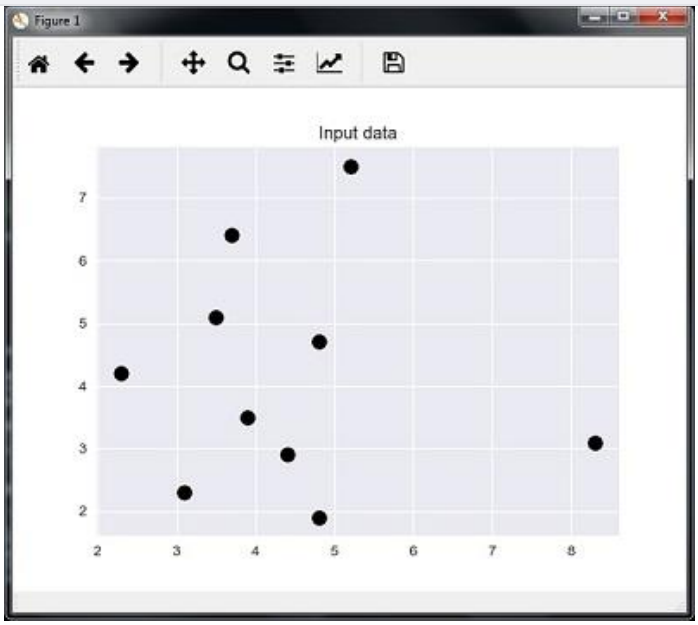

Теперь нам нужно построить ближайший сосед. Объекттакжедолженбытьобучен

```
knn_model = NearestNeighbors(n_neighbors = k, algorithm = 'auto').fit(X)
distances, indices = knn_model.kneighbors([test_data])
```

Теперь мы можем напечатать K ближайших соседей следующим образом

```
print("\nK Nearest Neighbors:")
for rank, index in enumerate(indices[0][:k], start = 1):
   print(str(rank) + " is", A[index])
```

Мы можем визуализировать ближайших соседей вместе с тестовой точкой данных

```
plt.figure()
plt.title('Nearest neighbors')
plt.scatter(A[:, 0], X[:, 1], marker = 'o', s = 100, color = 'k')
plt.scatter(A[indices][0][:][:, 0], A[indices][0][:][:, 1],
   marker = 'o', s = 250, color = 'k', facecolors = 'none')
plt.scatter(test_data[0], test_data[1],
   marker = 'x', s = 100, color = 'k')
plt.show()
```

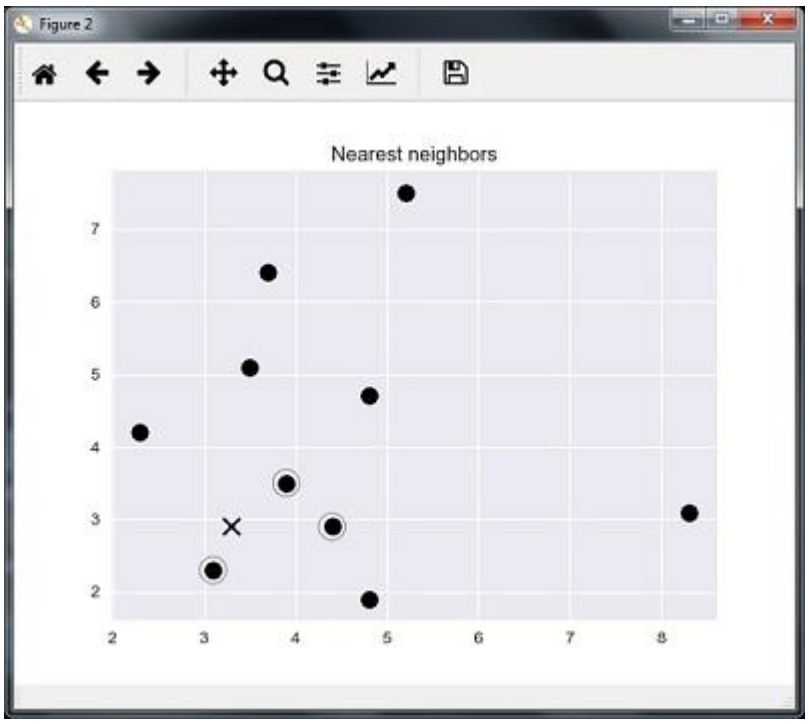

Классификатор ближайших соседей

Классификатор K-ближайших соседей (KNN) — это классификационная модель, которая использует алгоритм ближайших соседей для классификации данной точки данных. Мы реализовали алгоритм KNN в последнем разделе, а теперь мы собираемся построить классификатор KNN, используя этот алгоритм.

Концепция классификатора KHH

Основная концепция классификации K-ближайших соседей состоит в том, чтобы найти заранее определенное число, т. Е. «K» — обучающих выборок, ближайших по расстоянию к новой выборке, которую необходимо классифицировать. Новые образцы получат свою этикетку от самих соседей. Классификаторы KNN имеют фиксированную пользовательскую константу для числа соседей, которые должны быть определены. Для расстояния стандартное евклидово расстояние является наиболее распространенным выбором. Классификатор KNN работает непосредственно с изученными образцами, а не создает правила обучения. Алгоритм KNN является одним из самых простых алгоритмов машинного обучения. Это было довольно успешно в большом количестве проблем классификации и регрессии, например, распознавания символов или анализа изображений.

пример

Мы строим классификатор KNN для распознавания цифр. Для этого мы будем использовать набор данных MNIST. Мы напишем этот код в блокноте Jupyter.

Импортируйте необходимые пакеты, как показано ниже.

Здесь мы используем модуль **KNeighborsClassifier** из пакета **sklearn.neighbors** —

```
from sklearn.datasets import *
import pandas as pd
%matplotlib inline
from sklearn.neighbors import KNeighborsClassifier
import matplotlib.pyplot as plt
import numpy as np
```

Следующий код будет отображать изображение цифры, чтобы проверить, какое изображение мы должны проверить

```
def Image_display(i):
   plt.imshow(digit['images'][i],cmap = 'Greys_r')
plt.show()
```

Теперь нам нужно загрузить набор данных MNIST. На самом деле всего 1797 изображений, но мы используем первые 1600 изображений в качестве обучающего образца, а оставшиеся 197 будут сохранены для целей тестирования.

```
digit = load_digits()
digit_d = pd.DataFrame(digit['data'][0:1600])
```

Теперь при отображении изображений мы можем видеть вывод следующим образом:

```
Image_display(0)
```

Изображение 0 отображается следующим образом

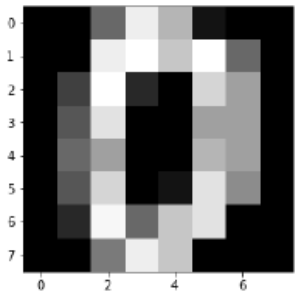

Теперь нам нужно создать набор данных обучения и тестирования и предоставить набор данных тестирования для классификаторов KNN.

```
train_x = digit['data'][:1600]
train_y = digit['target'][:1600]
KNN = KNeighborsClassifier(20)
KNN.fit(train_x,train_y)
```

Следующий вывод создаст конструктор классификатора ближайшего соседа —

```
KNeighborsClassifier(algorithm = 'auto', leaf_size = 30, metric = 'minkowski',
   metric_params = None, n_jobs = 1, n_neighbors = 20, p = 2,
weights = 'uniform')
```

Нам нужно создать тестовый образец, указав любое произвольное число больше 1600, которое было обучающим образцом.

```
test = np.array(digit['data'][1725])
test1 = test.reshape(1,-1)
Image_display(1725)
```

Теперь мы будем прогнозировать данные теста следующим образом

```
KNN.predict(test1)
```

Приведенный выше код сгенерирует следующий вывод:

```
array([6])
```

Теперь рассмотрим следующее

```
digit['target_names']
```

Приведенный выше код сгенерирует следующий вывод:

```
array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
```